

# Dự Đoán Doanh Thu Quán Cà Phê Sử dụng Mô hình Hồi quy Tuyến tính (Linear Regression)

Phạm Mạnh Giang Chu Nhật Ánh Nguyễn Hải Đăng

Tháng 7 năm 2026

## 1 Giới thiệu

Trong bối cảnh ngành dịch vụ ăn uống ngày càng phát triển, các quán cà phê không chỉ cạnh tranh về chất lượng sản phẩm mà còn cần tối ưu hóa hoạt động kinh doanh nhằm nâng cao hiệu quả và lợi nhuận. Một trong những yếu tố quan trọng giúp nhà quản lý đưa ra quyết định đúng đắn là khả năng dự đoán doanh thu trong tương lai. Việc dự báo doanh thu chính xác giúp quán cà phê chủ động hơn trong việc quản lý nguyên vật liệu, phân bổ nhân sự, xây dựng chiến lược kinh doanh và lập kế hoạch tài chính.

Hiện nay, Machine Learning đang được ứng dụng rộng rãi trong lĩnh vực phân tích dữ liệu và dự báo. Thông qua việc học từ dữ liệu lịch sử, các mô hình học máy có thể phát hiện mối quan hệ giữa các biến đầu vào và biến mục tiêu, từ đó đưa ra dự đoán cho những dữ liệu mới. Trong số các thuật toán học máy, Linear Regression là một trong những phương pháp cơ bản, dễ triển khai và có khả năng giải thích kết quả tốt, đặc biệt đối với các bài toán dự đoán giá trị liên tục.

Trong báo cáo này, nhóm sử dụng bộ dữ liệu *Coffee Shop Revenue* để xây dựng mô hình dự đoán doanh thu quán cà phê bằng thuật toán Linear Regression. Trước khi xây dựng mô hình, dữ liệu được tiền xử lý nhằm loại bỏ các giá trị không hợp lệ, kiểm tra dữ liệu trùng lặp và chuẩn hóa dữ liệu. Sau đó, nhóm tiến hành phân tích khám phá dữ liệu (Exploratory Data Analysis - EDA) để tìm hiểu đặc điểm của bộ dữ liệu cũng như mối quan hệ giữa các biến.

Sau khi hoàn thành các bước tiền xử lý và phân tích dữ liệu, mô hình Linear Regression được huấn luyện trên tập dữ liệu huấn luyện và đánh giá trên tập dữ liệu kiểm tra. Hiệu quả của mô hình được đánh giá thông qua các chỉ số MAE (Mean Absolute Error), MSE (Mean Squared Error), RMSE (Root Mean Squared Error) và hệ số xác định  $R^2$ . Ngoài ra, báo cáo cũng trực quan hóa kết quả dự đoán nhằm đánh giá mức độ phù hợp của mô hình với dữ liệu thực tế.

### 1.1 Mục tiêu của đề tài

Đề tài được thực hiện nhằm các mục tiêu sau:

- Tìm hiểu quy trình xây dựng mô hình dự đoán bằng Machine Learning.
- Tiền xử lý và làm sạch bộ dữ liệu Coffee Shop Revenue.

- Phân tích đặc điểm dữ liệu thông qua phương pháp EDA.
- Xây dựng mô hình Linear Regression để dự đoán doanh thu.
- Đánh giá hiệu quả mô hình bằng các chỉ số MAE, MSE, RMSE và  $R^2$ .
- Đề xuất hướng cải thiện mô hình trong các nghiên cứu tiếp theo.

## 1.2 Ý nghĩa của đề tài

Việc dự đoán doanh thu giúp nhà quản lý quán cà phê có cơ sở để lập kế hoạch kinh doanh, quản lý chi phí, tối ưu nguồn lực và nâng cao hiệu quả hoạt động. Bên cạnh đó, đề tài còn giúp người học làm quen với quy trình xây dựng một mô hình Machine Learning hoàn chỉnh, bao gồm các bước tiền xử lý dữ liệu, phân tích dữ liệu, xây dựng mô hình và đánh giá kết quả.

## 2 Mô tả bộ dữ liệu

### 2.1 Giới thiệu bộ dữ liệu

Trong nghiên cứu này, nhóm sử dụng bộ dữ liệu **Coffee Shop Revenue**, mô phỏng hoạt động kinh doanh của các quán cà phê. Bộ dữ liệu bao gồm nhiều thuộc tính phản ánh tình hình vận hành của quán như số lượng khách hàng, chi phí marketing, số lượng nhân viên, giá bán trung bình và doanh thu.

Biến mục tiêu của bài toán là **Revenue** (Doanh thu), trong khi các thuộc tính còn lại được sử dụng làm biến đầu vào để xây dựng mô hình dự đoán.

Bộ dữ liệu được lưu dưới định dạng CSV và được xử lý bằng thư viện Pandas trong ngôn ngữ lập trình Python.

### 2.2 Các thuộc tính của bộ dữ liệu

Một số thuộc tính chính trong bộ dữ liệu bao gồm:

- Number of Customers: Số lượng khách hàng.
- Average Order Value: Giá trị trung bình mỗi đơn hàng.
- Marketing Spend: Chi phí dành cho hoạt động marketing.
- Number of Employees: Số lượng nhân viên.
- Operating Hours: Thời gian hoạt động trong ngày.
- Location: Vị trí của quán.
- Revenue: Doanh thu (biến mục tiêu).

Các thuộc tính trên phản ánh những yếu tố có khả năng ảnh hưởng trực tiếp đến doanh thu của quán cà phê và được sử dụng để huấn luyện mô hình hồi quy tuyến tính.

## 3 Tiền xử lý dữ liệu

Chất lượng của dữ liệu đầu vào có ảnh hưởng rất lớn đến hiệu quả của mô hình học máy. Vì vậy, trước khi xây dựng mô hình, nhóm tiến hành tiền xử lý dữ liệu nhằm đảm bảo dữ liệu sạch, đầy đủ và phù hợp cho quá trình huấn luyện.

Quá trình tiền xử lý được thực hiện theo các bước sau.

### 3.1 Đọc dữ liệu

Đầu tiên, bộ dữ liệu được đọc từ tệp CSV bằng thư viện Pandas.

```
import pandas as pd
df = pd.read_csv("coffee_shop_revenue.csv")
```

Sau khi đọc dữ liệu, nhóm tiến hành kiểm tra số lượng bản ghi, số lượng thuộc tính và kiểu dữ liệu của từng cột bằng hàm `info()`.

### 3.2 Kiểm tra giá trị thiếu

Dữ liệu thiếu có thể làm giảm chất lượng của mô hình hoặc gây lỗi trong quá trình huấn luyện. Do đó, nhóm sử dụng hàm:

```
df.isnull().sum()
```

để kiểm tra số lượng giá trị thiếu ở từng thuộc tính.

Nếu xuất hiện giá trị thiếu, nhóm sẽ xem xét xử lý bằng cách loại bỏ hoặc thay thế tùy theo đặc điểm của từng thuộc tính.

### 3.3 Kiểm tra dữ liệu trùng lặp

Các bản ghi bị lặp có thể làm sai lệch kết quả phân tích và ảnh hưởng đến quá trình học của mô hình.

Để phát hiện dữ liệu trùng lặp, nhóm sử dụng:

```
df.duplicated().sum()
```

Nếu tồn tại dữ liệu trùng lặp, các bản ghi này sẽ được loại bỏ trước khi tiếp tục các bước xử lý tiếp theo.

### 3.4 Chuẩn hóa tên cột

Để thuận tiện trong việc lập trình và hạn chế lỗi khi truy cập dữ liệu, tên các cột được chuẩn hóa bằng cách chuyển toàn bộ sang chữ thường và thay khoảng trắng bằng dấu gạch dưới.

Việc chuẩn hóa giúp mã nguồn dễ đọc hơn và thống nhất trong toàn bộ dự án.

### 3.5 Kiểm tra kiểu dữ liệu

Sau khi làm sạch dữ liệu, nhóm tiếp tục kiểm tra kiểu dữ liệu của từng thuộc tính nhằm đảm bảo các biến số được lưu dưới đúng định dạng.

Đối với các thuộc tính dạng số, dữ liệu được giữ nguyên để phục vụ cho quá trình huấn luyện mô hình. Đối với các thuộc tính dạng phân loại, dữ liệu sẽ được chuyển đổi về dạng số nếu cần thiết trước khi đưa vào thuật toán học máy.

### 3.6 Lưu dữ liệu sau tiền xử lý

Sau khi hoàn thành các bước làm sạch dữ liệu, bộ dữ liệu đã xử lý được lưu lại thành một tệp CSV mới để sử dụng cho các bước phân tích khám phá dữ liệu (EDA) và xây dựng mô hình.


Việc lưu dữ liệu sau tiền xử lý giúp đảm bảo tính nhất quán giữa các lần thực nghiệm và thuận tiện cho việc tái sử dụng dữ liệu trong những nghiên cứu tiếp theo.

## 4 Phân tích khám phá dữ liệu (EDA)

Sau khi hoàn thành bước tiền xử lý, nhóm tiến hành phân tích khám phá dữ liệu (Exploratory Data Analysis - EDA). Mục đích của bước này là tìm hiểu đặc điểm của bộ dữ liệu, phát hiện các xu hướng, kiểm tra sự phân bố của các biến và xác định mối quan hệ giữa các thuộc tính trước khi xây dựng mô hình học máy.

### 4.1 Phân bố doanh thu

Nhóm sử dụng biểu đồ Histogram để quan sát sự phân bố của biến doanh thu.




Hình 1: Phân bố doanh thu của bộ dữ liệu

Từ Hình 1 có thể quan sát được cách doanh thu phân bố trong toàn bộ tập dữ liệu. Biểu đồ giúp xác định dữ liệu có phân bố chuẩn hay bị lệch, đồng thời hỗ trợ phát hiện các giá trị ngoại lai nếu xuất hiện.

## 4.2 Mỗi quan hệ giữa các thuộc tính

Để quan sát mối quan hệ giữa các biến đầu vào và doanh thu, nhóm sử dụng biểu đồ Pairplot.




Hình 2: Biểu đồ Pairplot giữa các thuộc tính

Pairplot cho phép quan sát trực quan mối quan hệ giữa từng cặp biến trong bộ dữ liệu. Nếu các điểm dữ liệu phân bố theo xu hướng tuyến tính thì Linear Regression sẽ có khả năng học tốt hơn.

## 4.3 Ma trận tương quan

Nhóm sử dụng hệ số tương quan Pearson để đánh giá mức độ tương quan giữa các thuộc tính.



Hình 3: Heatmap biểu diễn hệ số tương quan

Heatmap giúp xác định các thuộc tính có ảnh hưởng lớn đến doanh thu. Những biến có hệ số tương quan dương lớn thường có tác động tích cực đến doanh thu, trong khi các hệ số âm thể hiện mối quan hệ ngược chiều.

Ngoài ra, Heatmap còn giúp phát hiện hiện tượng đa cộng tuyến giữa các biến đầu vào, từ đó hỗ trợ lựa chọn đặc trưng phù hợp cho mô hình hồi quy tuyến tính.

#### 4.4 Nhận xét

Qua các bước phân tích EDA bao gồm thống kê mô tả, biểu đồ Histogram, Pairplot, Heatmap, nhóm đã có cái nhìn tổng quan về đặc điểm của bộ dữ liệu. Các biểu đồ cho thấy dữ liệu có sự khác biệt về phân bố giữa các biến, đồng thời tồn tại những mối quan hệ nhất định giữa các thuộc tính và doanh thu. Kết quả phân tích này là cơ sở quan trọng để lựa chọn mô hình Linear Regression và đánh giá khả năng dự đoán doanh thu ở các chương tiếp theo.

## 5 Xây dựng mô hình Linear Regression

Sau khi hoàn thành bước tiền xử lý và phân tích dữ liệu, nhóm tiến hành xây dựng mô hình Linear Regression nhằm dự đoán doanh thu của quán cà phê.

## 5.1 Lựa chọn biến

Biến mục tiêu được lựa chọn là:

- Revenue

Các thuộc tính còn lại được sử dụng làm biến đầu vào của mô hình.

## 5.2 Chia dữ liệu

Bộ dữ liệu được chia thành hai phần:

- 80% dữ liệu dùng để huấn luyện.
- 20% dữ liệu dùng để kiểm tra.

Việc chia dữ liệu giúp đánh giá khả năng dự đoán của mô hình trên các dữ liệu chưa từng xuất hiện trong quá trình huấn luyện.

## 5.3 Chuẩn hóa dữ liệu

Do các thuộc tính có đơn vị đo khác nhau nên nhóm sử dụng phương pháp StandardScaler để chuẩn hóa dữ liệu trước khi huấn luyện.

Việc chuẩn hóa giúp các đặc trưng có cùng thang đo, từ đó cải thiện hiệu quả của mô hình và giảm ảnh hưởng của các biến có giá trị quá lớn.

## 5.4 Mô hình hồi quy tuyến tính

Linear Regression mô tả mối quan hệ giữa các biến đầu vào và biến mục tiêu theo phương trình:

$$y = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \dots + \beta_n x_n$$

Trong đó:

- $y$  là doanh thu cần dự đoán.
- $x_i$  là các thuộc tính đầu vào.
- $\beta_i$  là các hệ số hồi quy.

Mục tiêu của mô hình là tìm các hệ số hồi quy sao cho sai số giữa giá trị dự đoán và giá trị thực tế là nhỏ nhất.

## 6 Đánh giá mô hình

Sau khi hoàn thành quá trình huấn luyện, mô hình Linear Regression được đánh giá trên tập dữ liệu kiểm tra (test set). Nhóm sử dụng bốn chỉ số phổ biến trong bài toán hồi quy gồm Mean Absolute Error (MAE), Mean Squared Error (MSE), Root Mean Squared Error (RMSE) và hệ số xác định ( $R^2$ ). Các chỉ số này giúp đánh giá mức độ sai số cũng như khả năng dự đoán của mô hình.

## 6.1 Mean Absolute Error (MAE)

Mean Absolute Error (MAE) là giá trị trung bình của sai số tuyệt đối giữa giá trị thực tế và giá trị dự đoán.

$$MAE = \frac{1}{n} \sum_{i=1}^n |y_i - \hat{y}_i| \quad (1)$$

Trong đó:

- $y_i$ : giá trị doanh thu thực tế.
- $\hat{y}_i$ : giá trị doanh thu dự đoán.
- $n$ : số lượng mẫu.

Giá trị MAE càng nhỏ thì mô hình dự đoán càng chính xác.

## 6.2 Mean Squared Error (MSE)

Mean Squared Error (MSE) là trung bình bình phương sai số giữa giá trị dự đoán và giá trị thực tế.

$$MSE = \frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2 \quad (2)$$

Do sai số được bình phương nên MSE sẽ phạt nặng các dự đoán có sai số lớn.

## 6.3 Root Mean Squared Error (RMSE)

Root Mean Squared Error (RMSE) là căn bậc hai của MSE.

$$RMSE = \sqrt{\frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2} \quad (3)$$

RMSE có cùng đơn vị với doanh thu nên dễ diễn giải hơn MSE. Giá trị RMSE càng nhỏ thì mô hình càng tốt.

## 6.4 Hệ số xác định ( $R^2$ )

Hệ số xác định ( $R^2$ ) dùng để đánh giá mức độ giải thích của mô hình đối với sự biến thiên của dữ liệu.

$$R^2 = 1 - \frac{\sum_{i=1}^n (y_i - \hat{y}_i)^2}{\sum_{i=1}^n (y_i - \bar{y})^2} \quad (4)$$

Trong đó:

- $\bar{y}$ : giá trị trung bình của doanh thu thực tế.

Giá trị  $R^2$  nằm trong khoảng từ 0 đến 1. Giá trị càng gần 1 thì mô hình càng giải thích tốt sự biến thiên của dữ liệu.

## 6.5 Kết quả đánh giá

Sau khi tính toán các chỉ số đánh giá, kết quả của mô hình Linear Regression được trình bày trong Bảng 1.


Bảng 1: Kết quả đánh giá mô hình Linear Regression

| Chỉ số | Giá trị    |
|--------|------------|
| MAE    | 254.881    |
| MSE    | 105902.672 |
| RMSE   | 325.426    |
| $R^2$  | 0.895      |

Từ Bảng 1 có thể nhận thấy mô hình đạt được các giá trị MAE, MSE và RMSE ở mức thấp, đồng thời hệ số  $R^2$  cho thấy khả năng giải thích của mô hình đối với dữ liệu. Kết quả này chứng minh mô hình Linear Regression có khả năng dự đoán doanh thu của quán cà phê với mức độ chính xác phù hợp trên bộ dữ liệu được sử dụng.

## 6.6 Biểu đồ so sánh giá trị thực tế và giá trị dự đoán

Để đánh giá trực quan khả năng dự đoán của mô hình, nhóm tiến hành so sánh doanh thu thực tế với doanh thu dự đoán trên tập dữ liệu kiểm tra.




Hình 4: So sánh doanh thu thực tế và doanh thu dự đoán

Hình 4 thể hiện mối quan hệ giữa giá trị doanh thu thực tế và giá trị doanh thu dự đoán của mô hình Linear Regression. Đường chéo biểu diễn trường hợp dự đoán hoàn toàn chính xác, trong đó các điểm dữ liệu nằm càng gần đường chéo thì sai số dự đoán càng nhỏ.

Quan sát biểu đồ cho thấy phần lớn các điểm dữ liệu phân bố xung quanh đường chéo, chứng tỏ mô hình có khả năng dự đoán khá tốt đối với bộ dữ liệu. Tuy nhiên, vẫn tồn tại một số điểm nằm xa đường chéo, cho thấy ở một số trường hợp mô hình dự đoán chưa thực sự chính xác. Nguyên nhân có thể đến từ sự ảnh hưởng của các giá trị ngoại lai hoặc mối quan hệ phi tuyến giữa các biến đầu vào và doanh thu.

## 6.7 Biểu đồ phần dư (Residual Plot)

Ngoài việc so sánh giá trị dự đoán với giá trị thực tế, nhóm còn sử dụng biểu đồ phần dư để đánh giá chất lượng của mô hình.



Hình 5: Biểu đồ phần dư của mô hình Linear Regression

Phần dư (Residual) được xác định bằng hiệu giữa giá trị thực tế và giá trị dự đoán của mô hình.

$$Residual = y - \hat{y}$$

Biểu đồ phần dư giúp kiểm tra xem các sai số của mô hình có phân bố ngẫu nhiên hay không. Nếu các điểm dữ liệu phân bố đều xung quanh đường giá trị bằng 0 và không hình thành xu hướng rõ rệt thì có thể kết luận mô hình phù hợp với dữ liệu.

Quan sát Hình 5 cho thấy phần lớn các điểm phần dư phân bố xung quanh đường 0 mà không tạo thành quy luật rõ ràng. Điều này cho thấy giả định tuyến tính của mô hình tương đối phù hợp và mô hình không xuất hiện hiện tượng sai lệch có hệ thống. Tuy nhiên, vẫn tồn tại một số điểm có phần dư lớn, phản ánh những trường hợp mô hình dự đoán chưa chính xác.

## 7 Kết luận

Trong báo cáo này, nhóm đã xây dựng mô hình dự đoán doanh thu quán cà phê sử dụng thuật toán Linear Regression trên bộ dữ liệu Coffee Shop Revenue. Quá trình thực hiện bao gồm các bước tiền xử lý dữ liệu, phân tích khám phá dữ liệu (EDA), xây dựng mô hình và đánh giá kết quả bằng các chỉ số MAE, MSE, RMSE và hệ số xác định  $R^2$ .

Kết quả thực nghiệm cho thấy mô hình Linear Regression có khả năng học được mối quan hệ giữa các đặc trưng đầu vào và doanh thu của quán cà phê. Mặc dù đây là một mô hình đơn giản, kết quả dự đoán đạt được tương đối tốt và có thể được sử dụng làm mô hình cơ sở (Baseline Model) cho bài toán dự đoán doanh thu.

Thông qua quá trình thực hiện đề tài, nhóm đã hiểu rõ hơn về quy trình xây dựng một mô hình Machine Learning hoàn chỉnh, từ bước chuẩn bị dữ liệu, trực quan hóa dữ liệu, huấn luyện mô hình đến đánh giá hiệu quả dự đoán. Đây là những kiến thức và kỹ năng quan trọng để tiếp cận các bài toán phân tích dữ liệu và dự đoán trong thực tế.

Trong tương lai, để nâng cao hiệu quả dự đoán, có thể mở rộng nghiên cứu bằng cách thử nghiệm các thuật toán hồi quy khác như Decision Tree Regression, Random Forest Regression hoặc XGBoost Regression. Đồng thời, việc thu thập thêm dữ liệu thực tế và thực hiện lựa chọn đặc trưng (Feature Selection) cũng có thể góp phần cải thiện độ chính xác và khả năng tổng quát của mô hình.

## Lời cảm ơn

Nhóm xin chân thành cảm ơn giảng viên đã tận tình hướng dẫn và hỗ trợ trong suốt quá trình thực hiện đề tài. Những kiến thức và góp ý của giảng viên đã giúp nhóm hoàn thành báo cáo này. Mặc dù đã cố gắng, báo cáo khó tránh khỏi những thiếu sót. Nhóm rất mong nhận được những ý kiến đóng góp để tiếp tục hoàn thiện kiến thức và kỹ năng trong các nghiên cứu sau.